



Graph-Based Movie Recommendation System dengan Analisis Kemiripan Pengguna pada Dataset MovieLens

Jeika Antama Syalom Tarigan (24031554011), Alifiyanti Putri Nur Azizah (24031554032),
Grace Pinkkan Ladyna (24031554137), Astrid Septya Regita Pramesty (24031554171)

Dosen Pengampu Mata Kuliah: Ulfa Siti Nuraini, S.Stat., M.Stat. dan Siska

Puspitaningsih, S.Kom., M.Kom.

Kelas 2024B

Program Studi Sains Data, Universitas Negeri Surabaya

Abstrak. Perkembangan layanan digital menyebabkan jumlah pilihan film yang tersedia semakin banyak sehingga pengguna sering mengalami kesulitan dalam menemukan film yang sesuai dengan referensinya. Penelitian ini bertujuan membangun sistem rekomendasi film berbasis Graph-Based Collaborative Filtering menggunakan dataset MovieLens 100K. Data diproses melalui tahap pembersihan data, pembentukan user-item matrix, perhitungan similarity antar pengguna menggunakan Cosine Similarity, serta konstruksi graph berdasarkan hubungan kemiripan pengguna. Analisis jaringan dilakukan melalui pengukuran struktur graph, community detection menggunakan algoritma Louvain, serta analisis centrality untuk mengidentifikasi pengguna yang memiliki pengaruh tinggi dalam jaringan. Sistem rekomendasi dibangun menggunakan pendekatan Weighted Recommendation Score yang memanfaatkan informasi dari pengguna dengan tingkat kemiripan tertinggi. Evaluasi dilakukan menggunakan Precision@10, Recall@10, dan Coverage pada tiga nilai threshold similarity, yaitu 0,15; 0,20; dan 0,25. Hasil penelitian menunjukkan bahwa peningkatan threshold menghasilkan rekomendasi yang lebih relevan, ditunjukkan oleh peningkatan nilai Precision@10 dari 0,0452 menjadi 0,1248 dan Recall@10 dari 0,0550 menjadi 0,1985. Namun, peningkatan threshold juga menurunkan Coverage dari 98,94% menjadi 55,36%. Hasil tersebut menunjukkan adanya trade-off antara kualitas rekomendasi dan jumlah pengguna yang dapat dilayani sistem. Secara keseluruhan, pendekatan Graph-Based Collaborative Filtering mampu memanfaatkan hubungan similarity antar pengguna untuk menghasilkan rekomendasi film yang personal dan relevan.

Kata kunci: Graph-Based Collaborative Filtering, MovieLens 100K, Community Detection, Centrality Analysis, Recommendation System.

BAB 1 Pendahuluan

A. Latar Belakang

Perkembangan teknologi digital dan platform streaming menyebabkan jumlah film yang tersedia semakin meningkat. Banyaknya pilihan film membuat pengguna sering mengalami kesulitan dalam menentukan film yang sesuai dengan preferensi mereka. Kondisi tersebut mendorong pentingnya sistem rekomendasi yang membantu pengguna memperoleh rekomendasi film secara lebih personal dan relevan berdasarkan histori penilaian pengguna terhadap film [1].

Salah satu metode yang umum digunakan dalam sistem rekomendasi adalah

collaborative filtering. Metode ini bekerja dengan memanfaatkan kemiripan preferensi antar pengguna untuk memberikan rekomendasi item yang relevan. Pengguna dengan pola *rating* yang mirip cenderung menyukai film yang sama sehingga informasi tersebut dapat digunakan sebagai dasar rekomendasi. Penelitian sebelumnya menunjukkan bahwa *collaborative filtering* dengan *cosine similarity* mampu menghasilkan rekomendasi yang lebih personal berdasarkan pola interaksi pengguna terhadap item [3].

Meskipun demikian, sistem rekomendasi konvensional masih memiliki beberapa kendala, seperti *sparsity* pada data rating dan keterbatasan dalam merepresentasikan hubungan kompleks antar pengguna dan item. Data *sparsity* terjadi karena sebagian besar pengguna hanya memberikan rating pada sebagian kecil film dibandingkan jumlah film yang tersedia. Kondisi tersebut dapat mempengaruhi kualitas perhitungan *similarity* dan hasil rekomendasi yang dihasilkan.

Untuk mengatasi permasalahan tersebut, pendekatan berbasis *graph* mulai banyak diterapkan dalam sistem rekomendasi. *Graph* mampu merepresentasikan hubungan antar pengguna dan item dalam bentuk jaringan sehingga hubungan antar entitas dapat dianalisis secara lebih fleksibel. Dalam *graph*, pengguna direpresentasikan sebagai *node* dan hubungan *similarity* direpresentasikan sebagai *edge*. Pendekatan *graph-based recommendation* memungkinkan analisis hubungan antar pengguna, pembentukan komunitas pengguna, serta identifikasi pola preferensi dalam jaringan [1].

Penelitian sebelumnya menunjukkan bahwa pendekatan *graph-based recommendation system* mampu meningkatkan kualitas rekomendasi dengan memanfaatkan hubungan antar pengguna dan item dalam bentuk jaringan *graph* [4]. Representasi *graph* memungkinkan hubungan antar *node* dianalisis secara lebih fleksibel sehingga pola interaksi pengguna dapat dimanfaatkan dalam proses rekomendasi. Selain itu, pendekatan *Graph-based Hybrid Recommendation System* juga menunjukkan kemampuan dalam meningkatkan performa rekomendasi melalui representasi hubungan pengguna dan item dalam *graph network* [5].

Berdasarkan penelitian tersebut, penelitian ini mengusulkan pembangunan *Graph-Based Movie Recommendation System* dengan *Analisis Kemiripan Pengguna pada Dataset MovieLens*. Penelitian menggunakan *MovieLens 100K Dataset* yang terdiri dari data rating pengguna (*u.data*) dan data informasi film (*u.item*) [2]. Kemiripan pengguna dihitung menggunakan *cosine similarity*, kemudian hasil *similarity* digunakan untuk membangun *graph* hubungan antar pengguna. Selain menghasilkan rekomendasi film, penelitian ini juga menganalisis struktur *graph* dan komunitas pengguna untuk memahami pola preferensi pengguna dalam jaringan.

B. Gambaran Umum Penelitian

Penelitian ini menggunakan dataset *MovieLens 100K* yang terdiri dari data *rating* pengguna dan informasi film. Tahapan penelitian dimulai dengan *preprocessing* data berupa data *cleaning*, *filtering user* dan *movie*, normalisasi *rating*, serta transformasi data ke dalam bentuk *user-item matrix*. Selanjutnya dilakukan perhitungan kemiripan menggunakan *cosine similarity*. Hasil *similarity* kemudian digunakan untuk membangun *graph network*, di mana *node* merepresentasikan pengguna dan *edge* merepresentasikan hubungan *similarity* antar pengguna. Penelitian ini juga menerapkan *threshold similarity*

untuk menentukan hubungan antar pengguna dalam *graph*. Selanjutnya dilakukan analisis *graph* menggunakan *community detection* untuk mengidentifikasi kelompok pengguna dengan preferensi yang serupa. Berdasarkan hubungan dalam *graph*, sistem rekomendasi film kepada pengguna berdasarkan film yang disukai oleh pengguna lain yang memiliki *similarity* tinggi dan berada dalam komunitas yang sama. Hal rekomendasi kemudian dievaluasi menggunakan *Precision@K* dan *Recall@K* untuk mengukur kualitas rekomendasi yang dihasilkan.

C. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun sistem rekomendasi film berbasis *graph* menggunakan *MovieLens* Dataset?
2. Bagaimana menghitung kemiripan antar pengguna menggunakan metode *Cosine Similarity*?
3. Bagaimana representasi *graph* dan analisis komunitas pengguna dapat digunakan untuk mendukung rekomendasi film?
4. Bagaimana kualitas rekomendasi film yang dihasilkan berdasarkan hubungan *similarity* antar pengguna dalam *graph*?

D. Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Membangun sistem rekomendasi film berbasis *graph* menggunakan *MovieLens* 100K.
2. Menghitung kemiripan pengguna menggunakan metode *cosine similarity*.
3. Menganalisis *similarity* struktur *graph* dan komunitas pengguna berdasarkan hubungan .
4. Menghasilkan rekomendasi film yang lebih personal berdasarkan hubungan antar pengguna dalam *graph*.

E. Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Membantu pengguna memperoleh rekomendasi film yang lebih relevan dan personal.
2. Memberikan pemahaman mengenai penerapan *graph* dalam sistem rekomendasi film.
3. Menjadi referensi pengembangan sistem rekomendasi berbasis *graph* dan *similarity* pengguna.
4. Memberikan *insight* mengenai hubungan dan pola preferensi pengguna dalam jaringan *graph*.

BAB 2 Metodologi Penelitian

A. Penjelasan Dataset

Dataset yang digunakan dalam penelitian ini adalah [MovieLens Dataset](https://grouplens.org/datasets/movielens/100k/) yang dikembangkan oleh *GroupLens Research* dan dapat diakses melalui <https://grouplens.org/datasets/movielens/100k/>. Dataset yang digunakan adalah MovieLens 100K yang terdiri dari sekitar 100.000 data rating yang diberikan oleh 943 pengguna terhadap 1.682 film. Nilai rating berada pada skala 1-5, di mana semakin tinggi rating menunjukkan tingkat ketertarikan pengguna terhadap film semakin besar. Dataset MovieLens dipilih karena memiliki struktur data *user-item* yang sesuai untuk analisis *recommendation system*, *cosine similarity*, *graph construction*, dan *community detection*.

Dataset yang digunakan terdiri dari dua file utama, yaitu *u.data* dan *u.item*. File *u.data* berisi data interaksi pengguna terhadap film, sedangkan file *u.item* berisi informasi detail mengenai film dan genre film. File *u.data* memiliki empat atribut utama, yaitu *user_id*, *item_id*, *rating*, dan *timestamp*. Kolom *user_id* menunjukkan identitas unik pengguna, *item_id* menunjukkan identitas unik film, *rating* menunjukkan nilai penilaian pengguna terhadap film pada skala 1–5, sedangkan *timestamp* menunjukkan waktu pemberian rating. Pada penelitian ini, atribut yang digunakan dari file *u.data* adalah *user_id*, *item_id*, dan *rating*, sedangkan atribut *timestamp* tidak digunakan karena tidak berkaitan langsung dengan proses analisis *similarity* dan pembentukan *graph*.


File *u.item* berisi informasi detail mengenai film. Setiap baris merepresentasikan satu film beserta atribut genre yang dimiliki film tersebut. Dataset ini memiliki 24 kolom, yaitu kolom 0 sebagai *item_id*, kolom 1 sebagai *title*, kolom 2 berisi tanggal rilis film, kolom 3 berisi *video release date*, kolom 4 berisi link IMDb, dan kolom 5–23 berisi atribut genre film dalam bentuk biner (0 dan 1). Pada atribut genre, nilai 1 menunjukkan bahwa film termasuk ke dalam genre tersebut, sedangkan nilai 0 menunjukkan bahwa film tidak termasuk ke dalam genre tersebut. Genre yang tersedia pada dataset meliputi *unknown*, *Action*, *Adventure*, *Animation*, *Children*, *Comedy*, *Crime*, *Documentary*, *Drama*, *Fantasy*, *Film-Noir*, *Horror*, *Musical*, *Mystery*, *Romance*, *Sci-Fi*, *Thriller*, *War*, dan *Western*.

Pada penelitian ini, atribut yang digunakan dari file *u.item* adalah *item_id*, *title*, dan atribut genre film. Kolom tanggal rilis, *video release date*, dan link IMDb tidak digunakan karena tidak berpengaruh langsung terhadap proses *similarity computation* maupun *community detection*. Dataset *u.item* digunakan untuk membantu interpretasi hasil analisis komunitas pengguna berdasarkan genre film yang disukai.

B. Progress Pengerjaan Proyek

Tahapan proyek yang telah dilakukan pada penelitian ini disajikan dalam bentuk diagram alur untuk menggambarkan proses analisis *graph mining* secara sistematis. Berdasarkan diagram alur yang telah dirancang, seluruh tahapan penelitian telah berhasil diselesaikan.

Gambar 1. Diagram Alur Pengerjaan Proyek



Berikut adalah uraian progress pengerjaan dari setiap tahapan:

1. Pengumpulan dan Pemahaman Dataset

Tahap awal yang dilakukan adalah memuat dataset dan memahami karakteristik data yang akan digunakan dalam proses analisis. Pada tahap ini dilakukan eksplorasi awal terhadap dataset untuk mengetahui jumlah user, jumlah item, serta pola interaksi yang terdapat pada data. Selain itu, dilakukan pengecekan terhadap struktur data dan distribusi interaksi guna memahami kondisi dataset sebelum dilakukan preprocessing.

Eksplorasi awal juga dilakukan untuk melihat tingkat sparsity pada data. Sparsity merupakan kondisi ketika sebagian besar nilai pada user-item matrix bernilai kosong karena user hanya berinteraksi dengan sebagian kecil item. Tingginya sparsity dapat mempengaruhi kualitas similarity antar user sehingga perlu dilakukan tahap preprocessing lebih lanjut.

2. Preprocessing Data

Tahap preprocessing bertujuan untuk meningkatkan kualitas data agar lebih siap digunakan dalam proses analisis. Proses ini diawali dengan data cleaning yang mencakup penghapusan missing value, data duplikat, serta validasi nilai rating agar berada dalam rentang yang sesuai. Selanjutnya dilakukan data filtering dengan mempertahankan hanya pengguna dan film yang memiliki jumlah interaksi minimal tertentu untuk mengurangi noise dan meningkatkan reliabilitas data. Selain itu, dilakukan analisis sparsity untuk mengetahui tingkat kekosongan data pada matriks user-item. Untuk mengurangi bias antar pengguna, diterapkan normalisasi rating menggunakan metode mean-centering, yaitu dengan

mengurangi setiap rating dengan rata-rata rating pengguna tersebut. Tahap ini juga dilengkapi dengan feature engineering, seperti penambahan informasi rata-rata rating, variansi, dan jumlah rating pengguna guna mendukung analisis lebih lanjut.

3. Pembentukan User Item Matrix

Pada tahap ini, data yang telah melalui proses preprocessing ditransformasikan ke dalam bentuk user-item matrix. Dalam matriks ini, baris merepresentasikan pengguna, kolom merepresentasikan film, dan nilai yang terdapat dalam matriks merupakan rating yang telah dinormalisasi. Untuk mengatasi nilai yang tidak tersedia, dilakukan pengisian dengan nilai nol agar proses komputasi dapat berjalan dengan lebih efisien. Matriks ini menjadi representasi utama data yang digunakan dalam proses perhitungan kemiripan antar pengguna.

4. Perhitungan Similarity Antar User

Setelah user-item matrix terbentuk, dilakukan perhitungan similarity antar user menggunakan metode cosine similarity. Tahap ini bertujuan untuk mengukur tingkat kemiripan preferensi antar pengguna. Metode yang digunakan adalah Cosine Similarity, yang menghitung kesamaan berdasarkan sudut antar vektor rating pengguna dalam ruang multidimensi. Nilai similarity yang dihasilkan berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan bahwa dua user memiliki pola interaksi yang semakin mirip. Hasil perhitungan similarity kemudian digunakan sebagai dasar dalam pembentukan edge pada graph.

5. Pembentukan Graph

Tahap berikutnya adalah membentuk graph berdasarkan hasil similarity antar user. Pada graph yang dibentuk, node merepresentasikan user sedangkan edge merepresentasikan hubungan similarity antar user. Dalam proses ini digunakan beberapa nilai threshold untuk menentukan batas minimum similarity agar hubungan antar user dapat dianggap cukup kuat untuk membentuk edge. Threshold yang digunakan pada penelitian ini yaitu 0.15, 0.20, dan 0.25.

Penggunaan threshold bertujuan untuk mengontrol kepadatan graph yang terbentuk. Semakin tinggi nilai threshold, maka hubungan antar user menjadi lebih selektif sehingga jumlah edge yang terbentuk akan semakin sedikit. Sebaliknya, threshold yang lebih rendah akan menghasilkan graph yang lebih padat karena lebih banyak hubungan similarity antar user yang memenuhi syarat untuk membentuk edge.

6. Analisis Pengaruh Threshold

Setelah graph terbentuk, dilakukan analisis terhadap pengaruh threshold terhadap struktur graph dan komunitas yang dihasilkan. Analisis dilakukan dengan membandingkan jumlah edge, jumlah komunitas, dan nilai modularity pada masing-masing threshold.

Hasil analisis menunjukkan bahwa peningkatan threshold menyebabkan jumlah edge menurun karena hubungan antar user menjadi lebih selektif. Sebaliknya, jumlah komunitas dan nilai modularity meningkat karena graph

terpecah menjadi kelompok-kelompok yang lebih spesifik. Analisis ini dilakukan untuk menentukan threshold yang paling optimal dalam proses community detection.

7. Pemilihan Threshold Optimal

Berdasarkan hasil analisis threshold, dilakukan pemilihan threshold optimal yang akan digunakan pada proses community detection. Threshold 0.20 dipilih sebagai threshold utama karena memberikan keseimbangan antara jumlah edge, jumlah komunitas, dan nilai modularity. Pada threshold ini, struktur komunitas yang terbentuk sudah cukup jelas namun graph belum terlalu terfragmentasi. Pemilihan threshold optimal dilakukan agar hasil community detection tetap representatif dan dapat digunakan untuk analisis lebih lanjut.

8. Community Detection

Setelah threshold optimal ditentukan, proses community detection dilakukan menggunakan algoritma Louvain untuk menemukan kelompok user yang memiliki hubungan lebih kuat di dalam komunitas dibandingkan dengan hubungan di luar komunitas. Algoritma Louvain dipilih karena mampu menghasilkan komunitas dengan kualitas modularity yang baik serta efisien dalam memproses graph berukuran besar. Hasil community detection kemudian dianalisis berdasarkan jumlah komunitas dan distribusi ukuran komunitas yang terbentuk sehingga dapat diketahui pola hubungan antar user dalam jaringan.

9. Analisis Centrality

Analisis centrality dilakukan untuk mengidentifikasi pengguna yang memiliki peran penting dalam jaringan. Dua metrik centrality yang digunakan adalah degree centrality dan betweenness centrality. Degree centrality mengukur seberapa banyak koneksi yang dimiliki suatu pengguna dibandingkan total pengguna lain dalam jaringan, sedangkan betweenness centrality mengukur seberapa sering suatu pengguna menjadi penghubung pada jalur terpendek antar pengguna lain.

10. Sistem Rekomendasi Berdasarkan Graph

Tahap selanjutnya adalah membangun sistem rekomendasi film berbasis graph menggunakan hubungan similarity antar pengguna yang telah terbentuk. Sebelum proses rekomendasi dilakukan, dataset dibagi menjadi data training dan data testing menggunakan strategi pemisahan berbasis pengguna. Data training digunakan untuk membangun sistem rekomendasi, sedangkan data testing digunakan untuk evaluasi.

Rekomendasi dihasilkan menggunakan metode *weighted similarity score* yang menghitung skor prediksi suatu film berdasarkan rata-rata rating tertimbang dari neighbor pengguna dalam graph. Neighbor diambil berdasarkan edge similarity pada graph utama (threshold 0,20), kemudian film yang sudah pernah ditonton pengguna target disaring sehingga hanya film baru yang direkomendasikan. Sistem menghasilkan Top-10 rekomendasi film untuk setiap pengguna berdasarkan skor prediksi tertinggi.

11. Evaluasi Sistem Rekomendasi

Evaluasi sistem rekomendasi dilakukan menggunakan metrik Precision@K dan Recall@K. Precision@K mengukur proporsi film relevan dari K film yang direkomendasikan, sedangkan Recall@K mengukur proporsi film relevan yang berhasil ditemukan dari seluruh film yang disukai pengguna pada data testing. Film dianggap relevan apabila memiliki nilai rating ≥ 4 pada data testing. Evaluasi dilakukan pada ketiga threshold eksperimen untuk mengetahui pengaruh struktur graph terhadap kualitas rekomendasi.

C. Penentuan Metrik Evaluasi

Evaluasi kinerja sistem rekomendasi pada penelitian ini dilakukan menggunakan tiga metrik, yaitu Precision@K, Recall@K, dan Coverage. Pemilihan ketiga metrik ini didasarkan pada kesesuaiannya dengan karakteristik sistem rekomendasi berbasis peringkat (*top-N recommendation*) yang berfokus pada relevansi item yang direkomendasikan kepada pengguna. Nilai K yang digunakan pada penelitian ini adalah K = 10 (*top-10 recommendation*).

1. Precision@K

Precision@K digunakan untuk mengukur ketepatan rekomendasi, yaitu proporsi film yang direkomendasikan dan benar-benar relevan terhadap total K item yang direkomendasikan. Metrik ini mencerminkan seberapa akurat sistem dalam menyaring film yang sesuai dengan preferensi pengguna.

2. Recall@K

Recall@K digunakan untuk mengukur kelengkapan rekomendasi, yaitu proporsi film relevan yang berhasil ditemukan sistem dari keseluruhan film relevan yang dimiliki pengguna pada *test set*. Metrik ini mencerminkan kemampuan sistem dalam mencakup seluruh preferensi pengguna.

3. Covarage

Covarage digunakan untuk mengukur jangkauan sistem, yaitu persentase pengguna yang berhasil memperoleh rekomendasi dari sistem terhadap total pengguna yang dievaluasi. Metrik ini penting untuk menilai apakah sistem mampu melayani sebagian besar pengguna, terutama mengingat adanya *isolated nodes* pada struktur *graph* yang menyebabkan sebagian pengguna tidak memiliki *neighbor*.

Sebuah film dianggap relevan apabila pengguna memberikan *rating* ≥ 4 pada *test set*, karena nilai tersebut mencerminkan bahwa pengguna menyukai film yang bersangkutan. Evaluasi dilakukan pada ketiga variasi *threshold* eksperimen (0,15; 0,20; dan 0,25) untuk menganalisis pengaruh struktur *graph* terhadap kualitas sistem rekomendasi secara menyeluruh.

BAB III Hasil dan Pembahasan

3.1 Data Understanding


Tahap data understanding dilakukan untuk memahami karakteristik dataset MovieLens 100K yang digunakan dalam penelitian. Dataset terdiri dari data rating pengguna (u.data) dan data informasi film (u.item). Dataset memiliki sekitar 100.000 data rating yang diberikan oleh 943 pengguna terhadap 1.682 film dengan rentang rating 1 hingga 5. Data rating digunakan untuk merepresentasikan preferensi pengguna terhadap film tertentu, sedangkan data film digunakan untuk mendukung analisis karakteristik komunitas berdasarkan genre film.

Tabel 1. Ringkasan Tabel Dataset MovieLens

Keterangan	Jumlah
Jumlah User	943
Jumlah Movie	1.682
Jumlah Rating	100.000
Rentang Rating	1-5

Berdasarkan Tabel 1, dataset MovieLens memiliki jumlah pengguna dan film yang cukup beragam sehingga sesuai digunakan untuk membangun dan mengevaluasi sistem rekomendasi berbasis graph.

Gambar 2. Distribusi dan Proporsi Rating Pengguna



Berdasarkan Gambar 2, terlihat bahwa distribusi rating pengguna tidak merata pada setiap nilai rating. Rating 4 merupakan rating yang paling banyak diberikan pengguna dengan jumlah 34.174 rating atau sekitar 34,2% dari total rating. Selanjutnya diikuti oleh rating 3 sebanyak 27.145 rating (27,15) dan rating 5 sebanyak 21.201 rating (21,2%). Sebaliknya, rating rendah relatif lebih sedikit diberikan oleh pengguna. Rating 2 berjumlah 11.370 rating (11,4%), sedangkan rating 1 merupakan rating paling sedikit diberikan yaitu sebanyak 6.110 rating (6,1%). Hasil tersebut menunjukkan bahwa sebagian besar pengguna cenderung memberikan penilaian positif terhadap film yang

ditonton. Hal ini terlihat dari dominasi rating 3, 4, dan 5 yang mencapai sekitar 82,5% dari keseluruhan data rating. Kondisi ini menunjukkan bahwa pengguna lebih sering memberikan penilaian menengah hingga tinggi dibandingkan penilaian rendah.

Selain analisis distribusi rating, dilakukan perhitungan sparsity untuk mengetahui tingkat kepadatan interaksi user-item pada dataset. Hasil perhitungan menunjukkan nilai sparsity sebesar 0.937. Nilai tersebut menunjukkan bahwa sekitar 93,7% kemungkinan interaksi antara pengguna dan film tidak memiliki rating. Dengan kata lain, hanya sebagian kecil film yang pernah diberi rating oleh setiap pengguna. Tingginya nilai sparsity menjadi salah satu tantangan utama dalam sistem rekomendasi berbasis collaborative filtering karena keterbatasan interaksi dapat menyebabkan hubungan antar pengguna sulit ditemukan. Oleh karena itu, penelitian ini memanfaatkan pendekatan graph-based recommendation untuk membantu mengidentifikasi hubungan similarity antar pengguna berdasarkan pola rating yang tersedia.

3.2 Data Preprocessing

Tahap preprocessing dilakukan untuk meningkatkan kualitas data agar siap digunakan dalam proses similarity computation dan graph construction. Dataset yang digunakan terdiri dari data informasi film (u.item) dan data rating pengguna (u.data). Pada data film dilakukan pemilihan atribut yang relevan, pengecekan missing value, penghapusan data duplikat, serta pembersihan judul film dengan menghapus spasi berlebih dan tahun rilis pada judul film agar data lebih konsisten.

Dataset u.item memiliki 24 kolom yang terdiri dari item_id, title, tanggal rilis film, video release date, link IMDb, dan atribut genre film dalam bentuk biner. Penelitian ini hanya menggunakan atribut item_id, title, dan atribut genre film karena atribut tersebut relevan untuk analisis karakteristik komunitas pengguna. Nilai atribut genre menggunakan representasi biner dengan nilai 1 menunjukkan bahwa film termasuk ke dalam genre tertentu dan nilai 0 menunjukkan bahwa film tidak termasuk ke dalam genre tersebut. Genre yang tersedia meliputi Action, Adventure, Animation, Children, Comedy, Crime, Documentary, Drama, Fantasy, Film-Noir, Horror, Musical, Mystery, Romance, Sci-Fi, Thriller, War, dan Western.

Hasil preprocessing menunjukkan bahwa dataset film tidak memiliki missing value maupun data duplikat berdasarkan item_id. Selain itu dilakukan penambahan atribut main_genre untuk menentukan genre utama setiap film berdasarkan atribut genre yang dimiliki. Pada data rating pengguna dilakukan proses data cleaning berupa pengecekan missing value, penghapusan duplikasi berdasarkan pasangan user_id dan item_id serta validasi nilai rating agar tetap berada pada rentang 1 hingga 5.

Selanjutnya dilakukan filtering data untuk mengurangi noise dan sparsity dataset. Filtering dilakukan dengan mempertahankan pengguna dan film yang memiliki minimal 20 interaksi rating. Selain itu, dilakukan normalisasi rating menggunakan metode mean-centering untuk mengurangi bias penilaian antar pengguna. Metode ini dilakukan dengan mengurangi nilai rating pengguna terhadap rata-rata rating pengguna tersebut.

Tabel 2. Ringkasan Hasil Preprocessing Data

Keterangan	Sebelum	Sesudah
Jumlah User	943	943
Jumlah Movie	1.682	939
Jumlah Rating	100.000	94.968

Berdasarkan Tabel 2, jumlah pengguna tetap sebanyak 943 user karena seluruh pengguna memenuhi minimal interaksi yang ditentukan. Namun jumlah film berkurang dari 1.682 menjadi 939 film karena hanya film dengan minimal 20 interaksi yang dipertahankan. Jumlah rating juga berkurang menjadi 94.968 interaksi setelah proses filtering. Selain itu, sparsity dataset setelah preprocessing turun menjadi 0,8927. Penurunan sparsity menunjukkan bahwa filtering berhasil meningkatkan kepadatan interaksi user-item sehingga hubungan antar pengguna menjadi lebih representatif untuk proses similarity computation.

3.3 Pembentukan User-Item Matrix

Setelah tahap preprocessing selesai dilakukan, data ditransformasikan ke dalam bentuk user-item matrix. Matriks ini digunakan untuk merepresentasikan hubungan antara pengguna dan film dalam bentuk tabel dua dimensi. Pada matriks tersebut, baris merepresentasikan pengguna (user_id), kolom merepresentasikan film (item_id), dan nilai pada matriks merupakan rating yang telah dinormalisasi menggunakan metode mean-centering.

Karena tidak semua pengguna memberikan rating pada seluruh film, terdapat banyak nilai kosong pada matriks. Untuk mempermudah proses perhitungan similarity, nilai yang tidak tersedia diisi menggunakan nilai 0. User-item matrix yang terbentuk menjadi representasi utama data dalam proses similarity computation dan graph construction. Contoh bentuk user-item matrix ditampilkan pada Gambar 2 untuk memperlihatkan representasi data yang digunakan dalam penelitian.

Shape User-Item Matrix: (943, 939)

item_id	1	2	3	4	5	6	7	8	9	10
user_id										
1	1.324111	-0.675889	0.324111	-0.675889	-0.675889	1.324111	0.324111	-2.675889	1.324111	-0.675889
2	0.233333	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	-1.766667
3	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
4	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
5	1.025157	0.025157	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000

Gambar 3. User-Item Matrix


Berdasarkan Gambar 3, nilai pada matriks menunjukkan rating hasil normalisasi pengguna terhadap film tertentu. Nilai positif menunjukkan bahwa pengguna memberikan rating di atas rata-rata rating pribadinya, sedangkan nilai negatif menunjukkan rating

berada di bawah rata-rata pengguna tersebut. Sebagai contoh, user 1 memiliki nilai 1,324111 pada item 1 yang menunjukkan bahwa pengguna memberikan penilaian lebih tinggi dibanding rata-rata rating pribadinya. Sebaliknya, nilai -2,675889 pada item 8 menunjukkan bahwa film tersebut dinilai jauh di bawah rata-rata rating user 1.

Nilai 0 pada matriks menunjukkan bahwa pengguna belum memberikan rating terhadap film tertentu. Pengisian missing value menggunakan nol dilakukan agar proses cosine similarity dapat dihitung secara efisien menggunakan representasi matriks sparse. User-item matrix yang terbentuk akan menjadi representasi utama data dalam proses similarity computation dan graph recommendation system.

3.4 Analisis Co-Rated Items

Selain menggunakan cosine similarity, penelitian ini juga mempertimbangkan jumlah co-rated items untuk meningkatkan validitas hubungan antar pengguna. Co-rated items merupakan jumlah film yang dinilai bersama oleh dua pengguna. Semakin banyak film yang dinilai bersama, maka hubungan similarity antar pengguna menjadi lebih valid dan representatif. Perhitungan co-rated items dilakukan menggunakan binary matrix yang menunjukkan apakah pengguna memberikan rating terhadap film tertentu atau tidak. Hasil perhitungan menghasilkan matriks co-rated berukuran 943×943 .



Gambar 4. Heatmap Co-Rated Items Antar Pengguna

Berdasarkan Gambar 4, warna yang semakin gelap menunjukkan jumlah film yang dinilai bersama semakin banyak, sedangkan warna terang menunjukkan interaksi bersama yang rendah. Sebagian besar pasangan pengguna memiliki jumlah co-rated items yang rendah. Hal tersebut menunjukkan bahwa dataset masih bersifat sparse karena setiap pengguna hanya memberikan rating pada sebagian kecil film yang tersedia. Namun, terdapat beberapa pasangan pengguna dengan jumlah co-rated items cukup

tinggi yang menunjukkan adanya kesamaan interaksi film antar pengguna. Pada penelitian ini digunakan minimum co-rated items sebesar 5 untuk membentuk hubungan antar pengguna pada graph recommendation system agar similarity yang dihasilkan lebih valid dan representatif.


3.5 Hasil Cosine Similarity Antar User

Tahap similarity computation dilakukan untuk mengukur tingkat kemiripan preferensi antar pengguna berdasarkan pola rating film yang diberikan. Metode yang digunakan adalah cosine similarity karena mampu mengukur kemiripan antar pengguna berdasarkan vektor rating pada user-item matrix. Hasil perhitungan menghasilkan matriks similarity berukuran 943×943 yang merepresentasikan hubungan antar seluruh pengguna pada dataset.

Tabel 3. Contoh Nilai Cosine Similarity Antar User

User	User 1	User 2	User 3	User 4	User 5
User 1	0,0000	0,0427	0,0163	0,0632	0,1513
User 2	0,0427	0,0000	0,0227	-0,0326	0,0357
User 3	0,0163	0,0227	0,0000	-0,0709	0,0161
User 4	0,0632	-0,0326	-0,0709	0,0000	0,0107
User 5	0,1513	0,0357	0,0161	0,0107	0,0000

Berdasarkan Tabel 3, sebagian besar nilai similarity berada di sekitar nol. Hal tersebut menunjukkan pola preferensi film yang serupa, sedangkan nilai similarity negatif menunjukkan preferensi yang cenderung berlawanan. Sebagai contoh, similarity 0,1513 antara user 1 dan user 5 menunjukkan bahwa mayoritas pengguna memiliki preferensi film yang cukup mirip. Sebaliknya, similarity sebesar -0,0709 antar user 3 dan user 4 menunjukkan bahwa kedua pengguna memiliki kecenderungan preferensi film yang berbeda. Nilai diagonal pada matriks similarity bernilai 0 karena self-similarity dihapus agar analisis hanya berfokus pada hubungan antar pengguna yang berbeda.



Gambar 5. Distribusi dan Boxplot Cosine Similarity Antar User

Berdasarkan Gambar 5, sebagian besar nilai similarity berada di sekitar nol dengan rata-rata similarity sebesar 0,024. Hal tersebut menunjukkan bahwa mayoritas pengguna

memiliki preferensi film yang berbeda-beda. Selain itu, terdapat beberapa pasangan pengguna dengan similarity tinggi yang menunjukkan adanya pengguna dengan pola preferensi yang mirip. Boxplot juga memperlihatkan bahwa sebagian besar nilai similarity terkonsentrasi di sekitar nol, meskipun terdapat beberapa outlier positif dan negatif. Kondisi ini menunjukkan bahwa hubungan antar pengguna cenderung sparse sehingga diperlukan threshold similarity untuk menyaring hubungan yang relevan pada proses graph construction.

Untuk memahami karakteristik similarity antar pengguna, dilakukan analisis statistik terhadap seluruh nilai cosine similarity. Hasil statistik ditampilkan pada Tabel 4.

Tabel 4. Statistik Cosine Similarity

Statistik	Nilai
Minimum	-0,4375
Maksimum	0,6408
Mean	0,0239
Median	0,0165
Standar Deviasi	0,0602

Berdasarkan Tabel 4, nilai rata-rata similarity yang mendekati nol menunjukkan bahwa tingkat kemiripan antar pengguna relatif rendah. Nilai maksimum sebesar 0,6408 menunjukkan adanya beberapa pasangan pengguna dengan preferensi yang sangat mirip, sedangkan nilai minimum negatif menunjukkan adanya pengguna dengan preferensi yang berlawanan. Hasil ini menunjukkan bahwa pemilihan threshold similarity menjadi penting dalam pembentukan graph recommendation system

3.6 Analisis Threshold


Threshold similarity digunakan untuk menentukan apakah hubungan antar pengguna cukup kuat untuk dibentuk menjadi edge pada graph recommendation system. Semakin tinggi threshold, maka graph yang terbentuk akan semakin selektif dan sparse. Untuk menentukan threshold yang sesuai, dilakukan eksperimen menggunakan beberapa nilai threshold dari 0,10 hingga 0,40. Analisis dilakukan berdasarkan jumlah edge, density graph, dan average degree.

Tabel 5. Analisis Pengaruh Threshold terhadap Struktur Graph

Threshold	Jumlah Edge	Density	Average Degree
0,10	41.187	0,092732	87,35
0,15	12.489	0,028119	26,49
0,20	3.587	0,008076	7,61
0,25	1.119	0,002519	2,37
0,30	124	0,000838	0,79

0,35	124	0,000279	0,26
0,40	48	0,000108	0,10

Berdasarkan Tabel 5, peningkatan threshold menyebabkan jumlah edge menurun secara signifikan. Pada threshold rendah, graph menjadi sangat padat karena terlalu banyak hubungan similarity yang dianggap relevan. Sebaliknya, pada threshold tinggi graph menjadi terlalu sparse dan banyak pengguna tidak saling terhubung. Threshold 0,15 hingga 0,25 dipilih sebagai threshold eksperimen karena masih mampu menghasilkan graph yang cukup terhubung namun tetap selektif dalam membentuk hubungan antar pengguna.



Gambar 6. Visualisasi Pengaruh Threshold terhadap Struktur Graph

Berdasarkan Gambar 6, seluruh metrik graph mengalami penurunan seiring meningkatnya threshold similarity. Penurunan paling terlihat terjadi pada jumlah edge dan average degree. Hal tersebut menunjukkan bahwa sebagian besar pasangan pengguna hanya memiliki similarity rendah sehingga akan tereliminasi ketika threshold dinaikkan. Selain itu, density graph juga semakin kecil yang menandakan hubungan antar pengguna menjadi lebih jarang. Garis merah pada grafik menunjukkan threshold eksperimen utama yaitu 0,15, 0,20, dan 0,25 yang digunakan pada tahap graph construction dan community detection.

3.7 Graph Construction

3.7.1 Pembentukan Graph

Graph construction dilakukan untuk membentuk jaringan hubungan antar pengguna berdasarkan nilai cosine similarity. Pada graph yang terbentuk, node merepresentasikan pengguna sedangkan edge merepresentasikan hubungan similarity antar pengguna. Graph dibangun menggunakan threshold similarity dan minimum co-rated items sebesar 5 untuk meningkatkan validitas hubungan antar pengguna. Dengan demikian, edge hanya dibentuk apabila dua pengguna memiliki similarity di atas threshold dan memiliki minimal lima film yang dinilai bersama. Penelitian ini menggunakan tiga threshold eksperimen yaitu 0,15, 0,20, dan 0,25.


Tabel 6. Ringkasan Struktur Graph

Threshold	Nodes	Edges	Density	Avg Degree	Components
0,15	943	12.489	0,028119	26,49	11
0,20	943	3.587	0,008076	7,61	157
0,25	943	1.119	0,002519	2,37	454

Berdasarkan Tabel 7, seluruh graph memiliki jumlah node yang sama yaitu 943 pengguna. Namun semakin tinggi threshold menyebabkan jumlah edge menurun secara signifikan dan jumlah connected component meningkat. Pada threshold 0,15 graph masih cukup padat dengan 12.489 edge dan hanya memiliki 11 connected component. Hal tersebut menunjukkan bahwa sebagian besar pengguna masih saling terhubung. Pada threshold 0,20 jumlah edge menurun menjadi 3.587 edge dengan 157 connected component. Kondisi ini menunjukkan bahwa hubungan antar pengguna mulai lebih selektif sehingga struktur komunitas mulai terlihat lebih jelas. Sementara itu pada threshold 0,25 graph menjadi jauh lebih sparse dengan hanya 1.119 edge dan 454 connected component. Banyak pengguna menjadi terisolasi sehingga graph mengalami fragmentasi yang tinggi.

3.7.2 Visualisasi Sub-Graph

Visualisasi sub-graph dilakukan pada 3 threshold eksperimen yaitu, 0,15, 0,20, dan 0,25. Visualisasi sub-graph tiap threshold sebagai berikut:



Gambar 7. Visualisasi Subgraph pada Berbagai Threshold

Berdasarkan Gambar 7, threshold 0,15 menghasilkan graph yang relatif padat dengan banyak hubungan antar node. Struktur graph terlihat masih saling terhubung sehingga komunitas pengguna belum terlihat secara jelas. Pada threshold 0,20 graph mulai membentuk kelompok-kelompok kecil yang lebih terpisah. Hubungan antar pengguna menjadi lebih selektif sehingga pola komunitas mulai terlihat dengan lebih baik dibandingkan threshold sebelumnya. Sementara itu pada threshold 0,25 graph menjadi jauh lebih sparse dan banyak node yang terisolasi tanpa hubungan dengan node lain. Hal tersebut menunjukkan bahwa threshold terlalu tinggi dapat menyebabkan hilangnya banyak hubungan antar pengguna yang sebenarnya masih relevan. Berdasarkan hasil visualisasi dan analisis struktur graph, threshold 0,20 dipilih sebagai threshold utama

karena memberikan keseimbangan antara jumlah edge, keterhubungan graph, dan pembentukan komunitas pengguna.

3.7.3 Statistik Graph

Tabel berikut menyajikan statistik struktur graph secara lengkap untuk ketiga nilai threshold eksperimen. Seluruh graph memiliki jumlah node yang sama yaitu 943 pengguna, namun struktur konektivitasnya berbeda secara signifikan seiring meningkatnya nilai threshold.


Tabel 7. Statistik Graph

Threshold	0.15	0.2	0.25
n_nodes	943	943	943
n_edges	12.489	3.587	1.119
density	0,028119	0,008076	0,002519
avg_degree	26,49	7,61	2,37
max_degree	147	64	28
min_degree	0	0	0
median_degree	21	4	1
n_components	11	157	454
largest_cc_size	933	776	442
largest_cc_pct	98,94%	82,29%	46,87%
n_isolated	10	147	421
isolated_pct	1,06%	15,59%	44,64%
avg_weight	0,1911	0,2438	0,2962
max_weight	0,6408	0,6408	0,6408
min_weight	0.15	0.20	0.25

Berdasarkan pada Tabel 7. Statistik Graph pada threshold 0,15 terbentuk 12.489 edge dengan density 0,028 dan rata-rata degree 26,49 yang menunjukkan bahwa setiap pengguna rata-rata terhubung dengan 26 pengguna lain. Degree tertinggi mencapai 147 yang menandakan adanya pengguna dengan koneksi sangat banyak dalam jaringan. Pada threshold 0,20 jumlah edge berkurang menjadi 3.587 dengan rata-rata degree 7,61 dan degree tertinggi 64, sedangkan pada threshold 0,25 hanya terbentuk 1.119 edge dengan rata-rata degree 2,37. Penurunan jumlah edge yang signifikan ini menunjukkan bahwa peningkatan threshold menyebabkan hanya pasangan pengguna dengan kemiripan preferensi yang benar-benar tinggi yang terhubung dalam jaringan.

3.7.4 Degree Distribution

Degree distribution menggambarkan sebaran jumlah koneksi yang dimiliki setiap pengguna dalam jaringan. Analisis ini penting untuk memahami karakteristik struktur graph secara keseluruhan.




Gambar 8. Visualisasi Degree Distribution

Berdasarkan Gambar 8. visualisasi degree distribution, distribusi koneksi antar pengguna bersifat *right-skewed* (condong ke kanan) pada ketiga threshold. Sebagian besar pengguna memiliki degree yang rendah, sementara hanya sedikit pengguna yang memiliki degree sangat tinggi. Pola ini mengindikasikan adanya karakteristik jaringan skala bebas (*scale-free network*), di mana terdapat sejumlah kecil pengguna yang berperan sebagai *hub* dengan koneksi jauh lebih banyak dibandingkan pengguna lainnya. Pada threshold 0,15 degree tertinggi mencapai 147, menurun menjadi 64 pada threshold 0,20, dan 28 pada threshold 0,25, konsisten dengan menurunnya kepadatan graph seiring meningkatnya threshold. Plot log-log pada baris bawah mempertegas karakteristik *scale-free* tersebut, di mana titik-titik data membentuk pola linier pada skala logaritmik yang merupakan ciri khas distribusi *power law* pada jaringan nyata.

3.7.5 Analisis Isolated Nodes

Isolated nodes merupakan pengguna yang tidak memiliki satupun koneksi dalam graph, yaitu pengguna dengan nilai degree sama dengan nol. Kondisi ini terjadi karena nilai cosine similarity pengguna tersebut dengan seluruh pengguna lain tidak memenuhi syarat threshold maupun jumlah co-rated items minimum.




Gambar 9. Barchart User Terhubung vs Terisolasi

Berdasarkan Gambar 9. menunjukkan adanya peningkatan jumlah pengguna terisolasi seiring meningkatnya threshold. Pada threshold 0,15 hanya terdapat 10 pengguna terisolasi, yang berarti hampir seluruh pengguna berhasil terhubung dalam jaringan. Pada threshold 0,20 jumlah pengguna terisolasi meningkat menjadi 147 pengguna, sedangkan pada threshold 0,25 sebanyak 421 pengguna tidak memiliki koneksi sama sekali. Pengguna terisolasi ini umumnya merupakan pengguna yang memiliki selera film yang sangat spesifik atau jumlah rating yang terbatas sehingga tidak memiliki cukup kesamaan dengan pengguna lain. Tingginya jumlah *isolated nodes* pada threshold 0,25 menjadi salah satu pertimbangan utama mengapa threshold tersebut kurang ideal untuk digunakan sebagai konfigurasi utama sistem rekomendasi, karena hampir separuh pengguna tidak dapat memperoleh rekomendasi dari jaringan.

3.7.6 Analisis Largest Connected Component (LCC)

Largest Connected Component (LCC) merupakan komponen terbesar dalam graph yang menghubungkan node-node secara langsung maupun tidak langsung. Ukuran LCC mencerminkan seberapa besar porsi pengguna yang masih berada dalam satu jaringan besar yang saling terhubung.




Gambar 10. Barchart Visualisasi LCC

Berdasarkan Gambar 10. Barchart Visualisasi LCC menunjukkan porsi pengguna yang masih berada dalam satu jaringan besar. Threshold 0,15 menghasilkan LCC terbesar dengan 933 pengguna, diikuti threshold 0,20 dengan 776 pengguna, dan threshold 0,25 dengan 442 pengguna. Penurunan LCC pada threshold 0,25 mengindikasikan bahwa

jaringan telah terfragmentasi secara signifikan sehingga kurang ideal untuk analisis komunitas.

3.7.7 Distribusi Bobot Edge

Bobot edge merepresentasikan nilai cosine similarity dari pasangan pengguna yang berhasil terhubung dalam graph. Analisis distribusi bobot edge memberikan informasi mengenai kualitas koneksi yang terbentuk pada setiap konfigurasi threshold.




Gambar 11. Visualisasi Distribusi Bobot Edge

Gambar 11. Visualisasi Distribusi Bobot Edge menunjukkan bahwa pada threshold 0,15, bobot terkonsentrasi di rentang 0,15 hingga 0,25 dengan rata-rata 0,19. Pada threshold 0,20 distribusi bergeser ke kanan dengan rata-rata bobot 0,24, sedangkan pada threshold 0,25 rata-rata bobot mencapai 0,29. Pola ini menunjukkan bahwa semakin tinggi threshold, edge yang tersisa merupakan koneksi dengan kualitas similarity yang semakin tinggi. Dengan kata lain, meskipun jumlah edge berkurang, setiap edge yang terbentuk merepresentasikan hubungan kemiripan yang lebih kuat dan lebih bermakna antar pengguna.

3.7.8 Visualisasi Perbandingan Graph

Visualisasi perbandingan graph pada ketiga threshold menggabungkan informasi struktur jaringan dengan atribut node dan edge secara sekaligus. Ukuran node merepresentasikan nilai degree pengguna sehingga pengguna yang lebih berpengaruh terlihat lebih besar, sedangkan ketebalan edge merepresentasikan bobot cosine similarity sehingga koneksi yang lebih kuat terlihat lebih tebal.



Gambar 12. Visualisasi Perbandingan Graph 3 Threshold

Pada threshold 0,15 terlihat banyak node berukuran besar yang tersebar merata, mengindikasikan adanya banyak pengguna yang berperan sebagai hub dalam jaringan dengan LCC mencakup 98,94% pengguna. Pada threshold 0,20 ukuran node mulai bervariasi dengan beberapa hub yang lebih menonjol, sementara edge yang tersisa cenderung lebih tebal yang menandakan kemiripan yang lebih kuat. Pada threshold 0,25 sebagian besar node berukuran kecil dengan sedikit koneksi dan jaringan tampak lebih terfragmentasi, konsisten dengan nilai LCC yang hanya 46,87%.

Berdasarkan seluruh analisis struktur graph yang telah dilakukan, threshold 0,20 terbukti menjadi konfigurasi yang paling optimal. Threshold tersebut menghasilkan keseimbangan terbaik antara jumlah koneksi yang representatif (3.587 edge), tingkat *isolated nodes* yang masih dapat diterima (15,59%), dan LCC yang mencakup mayoritas pengguna (82,29%). Temuan ini memperkuat keputusan penggunaan threshold 0,20 sebagai konfigurasi utama dalam tahap analisis graph dan sistem rekomendasi selanjutnya.

3.8 Community Detection

3.8.1 Hasil Community Detection

Tahap community detection dilakukan untuk mengelompokkan pengguna berdasarkan kemiripan preferensi film pada graph recommendation system. Metode yang digunakan adalah Louvain Community Detection karena mampu mendeteksi komunitas secara efektif pada graph berbobot. Proses community detection dilakukan pada graph dengan threshold 0,15, 0,20, dan 0,25. Hasil pengujian ditampilkan pada Tabel 8.

Tabel 8. Hasil Community Detection


Threshold	Jumlah Komunitas	Modularity
0,15	17	0,4299
0,20	168	0,5017
0,25	465	0,6017

Berdasarkan Tabel 8, semakin tinggi threshold maka jumlah komunitas dan nilai modularity meningkat. Hal tersebut menunjukkan bahwa graph menjadi lebih selektif sehingga komunitas yang terbentuk semakin spesifik. Threshold 0,20 dipilih sebagai graph utama karena menghasilkan keseimbangan antara jumlah komunitas, connectivity graph, dan nilai modularity.

Pada threshold 0,20 terbentuk 168 komunitas dengan modularity sebesar 0,5017. Nilai tersebut menunjukkan bahwa struktur komunitas pada graph tergolong cukup baik. Ukuran komunitas yang terbentuk juga bervariasi. Komunitas terbesar terdiri dari 203 pengguna, sedangkan beberapa komunitas hanya berisi satu pengguna. Rata-rata ukuran komunitas adalah 5,6 pengguna. Perbedaan ukuran komunitas menunjukkan bahwa terdapat kelompok pengguna dengan preferensi film yang mirip, namun terdapat juga pengguna dengan preferensi yang lebih unik.

3.8.2 Visualisasi Graph Komunitas

Visualisasi Graph Komunitas direpresentasikan pada gambar berikut:




Gambar 13. Visualisasi Graph Komunitas Pengguna

Berdasarkan Gambar 13, node merepresentasikan pengguna dan edge menunjukkan hubungan similarity antar pengguna. Warna node menunjukkan komunitas hasil Louvain Community Detection. Terlihat bahwa pengguna dengan preferensi film yang mirip cenderung berkumpul dalam kelompok yang sama. Hubungan di dalam komunitas terlihat lebih rapat dibanding hubungan antar komunitas, sehingga menunjukkan bahwa proses community detection berhasil memisahkan kelompok pengguna berdasarkan kemiripan preferensi film. Ukuran node menunjukkan jumlah koneksi yang dimiliki pengguna. Semakin besar ukuran node maka semakin banyak hubungan similarity yang dimiliki pengguna tersebut dalam graph.

3.8.3 Top 15 Komunitas Terbesar dan Perbandingan Modularity per Threshold

Untuk melihat top 15 komunitas terbesar digunakan visualisasi menggunakan barchart sebagai berikut:



Gambar 14. Top 15 Komunitas Terbesar dan Perbandingan Modularity

Berdasarkan Gambar 8, sebagian besar komunitas memiliki jumlah pengguna yang relatif kecil, sedangkan hanya beberapa komunitas yang memiliki jumlah pengguna besar. Hal tersebut menunjukkan bahwa preferensi pengguna pada dataset cukup beragam. Selain itu, peningkatan threshold menyebabkan jumlah komunitas dan nilai modularity meningkat. Kondisi tersebut menunjukkan bahwa graph menjadi lebih selektif sehingga komunitas yang terbentuk semakin spesifik dan terpisah dengan lebih jelas.


3.8.4 Penggabungan dengan Dataset Film

Setelah proses *community detection* selesai dilakukan, hasil pengelompokan komunitas digabungkan dengan dataset film untuk memperoleh informasi genre film yang disukai oleh setiap komunitas. Proses penggabungan dilakukan dalam dua tahap. Tahap pertama adalah menggabungkan data *rating* pengguna dengan hasil *community detection* berdasarkan *user_id*, sehingga setiap interaksi *rating* memiliki informasi komunitas pengguna yang bersangkutan. Tahap kedua adalah menggabungkan data tersebut dengan dataset film (*u.item*) berdasarkan *item_id* untuk memperoleh informasi judul film dan genre utama (*main_genre*).

Hasil penggabungan menghasilkan satu tabel terpadu yang memuat informasi *user_id*, *community_id*, *item_id*, *rating*, *title*, dan *main_genre* untuk setiap interaksi. Tabel terpadu ini menjadi dasar analisis genre dominan dan karakteristik komunitas pada tahap selanjutnya.

3.8.5 Genre Dominan per Komunitas

Genre dominan setiap komunitas ditentukan berdasarkan genre film yang paling sering muncul pada interaksi *rating* dalam komunitas tersebut. Perhitungan dilakukan dengan mengelompokkan data berdasarkan *community_id* dan *main_genre*, kemudian menghitung jumlah interaksi *rating* untuk setiap kombinasi komunitas dan genre. Genre dengan jumlah interaksi terbanyak pada setiap komunitas dipilih sebagai genre dominan yang mencerminkan preferensi kolektif pengguna dalam komunitas tersebut.



Gambar 16. Genre Dominan pada Tiap Komunitas

Berdasarkan hasil analisis, setiap komunitas memiliki genre dominan yang berbeda-beda. Hal ini membuktikan bahwa algoritma Louvain berhasil mengelompokkan pengguna berdasarkan kesamaan selera film, bukan sekadar berdasarkan frekuensi *rating*. Genre Drama dan Comedy merupakan genre yang paling sering muncul sebagai genre dominan di berbagai komunitas, konsisten dengan distribusi *rating* keseluruhan dataset yang didominasi oleh kedua genre tersebut. Namun demikian, terdapat pula komunitas dengan genre dominan yang lebih spesifik seperti *Action*, *Thriller*, dan *Romance*, yang menunjukkan bahwa terdapat kelompok pengguna dengan preferensi genre yang lebih khusus.

3.8.6 Karakteristik Komunitas


Analisis karakteristik komunitas dilakukan untuk memahami profil setiap komunitas secara lebih mendalam. Karakteristik yang dihitung meliputi jumlah pengguna unik (*total_users*), jumlah film unik yang pernah diberi *rating* (*total_movies*), rata-rata *rating* yang diberikan (*avg_rating*), dan genre dominan pada setiap komunitas.

Berdasarkan hasil analisis, ukuran komunitas bervariasi cukup signifikan. Komunitas terbesar terdiri dari 203 pengguna, sementara beberapa komunitas hanya beranggotakan satu pengguna. Rata-rata ukuran komunitas adalah 5,6 pengguna. Kondisi ini mencerminkan bahwa sebagian besar pengguna memiliki preferensi yang cukup unik dan hanya sedikit yang berbagi selera serupa dengan banyak pengguna lain. Nilai rata-rata *rating* antar komunitas juga bervariasi, yang mengindikasikan adanya perbedaan kecenderungan penilaian antar kelompok pengguna. Perbedaan karakteristik antar komunitas ini mempertegas bahwa proses *community detection* berhasil membentuk kelompok-kelompok pengguna yang memiliki pola preferensi yang berbeda satu sama lain.

3.8.7 User Paling Berpengaruh per Komunitas

Identifikasi pengguna paling berpengaruh pada setiap komunitas dilakukan menggunakan metrik *degree centrality*. Pengguna dengan nilai *degree centrality* tertinggi dalam suatu komunitas dianggap sebagai pengguna yang paling banyak memiliki koneksi *similarity* dengan pengguna lain dalam komunitas tersebut, sehingga preferensinya paling representatif di antara seluruh anggota komunitas.

Proses identifikasi dilakukan dengan menggabungkan data *degree centrality* seluruh pengguna dengan informasi komunitas hasil *community detection*. Selanjutnya, untuk setiap komunitas diambil satu pengguna dengan nilai *degree centrality* tertinggi sebagai pengguna paling berpengaruh. Pengguna dengan pengaruh tertinggi ini berpotensi dijadikan acuan rekomendasi film bagi anggota komunitas lainnya, karena preferensinya paling banyak bersinggungan dengan pengguna lain yang memiliki selera serupa dalam jaringan.



Gambar 17. Top 10 User Paling Berpengaruh per Komunitas

Hasil analisis menunjukkan bahwa pengguna paling berpengaruh di setiap komunitas berasal dari komunitas yang berbeda-beda. Komunitas 0 dan komunitas 3 terlihat paling dominan dalam menghasilkan pengguna dengan *degree centrality* tinggi, konsisten dengan temuan pada analisis *centrality* sebelumnya yang menunjukkan bahwa komunitas tersebut merupakan komunitas dengan konektivitas jaringan terkuat.

3.9 Analisis Centrality

Analisis centrality dilakukan untuk mengetahui tingkat pengaruh pengguna dalam graph recommendation system. Pada penelitian ini digunakan dua jenis centrality, yaitu degree centrality dan betweenness centrality. Degree centrality digunakan untuk mengukur banyaknya koneksi similarity yang dimiliki pengguna terhadap pengguna lain, sedangkan betweenness centrality digunakan untuk mengukur peran pengguna sebagai penghubung antar node dalam graph

3.9.1 Degree Centrality

Degree centrality dihitung menggunakan fungsi `nx.degree_centrality(G_main)` pada graph utama hasil pembentukan similarity antar pengguna. Nilai degree centrality menunjukkan seberapa banyak hubungan similarity yang dimiliki setiap pengguna terhadap pengguna lainnya di dalam jaringan.

Tabel 9. Hasil Degree Centrality

user_id	Betweenness
1	0.005380
2	0.019108
3	0.004246
4	0.015924
5	0.003185

Hasil degree centrality menunjukkan bahwa sebagian besar pengguna memiliki nilai centrality yang relatif kecil. Pada lima data awal, nilai degree centrality berada pada rentang 0.003 hingga 0.019. Nilai tertinggi pada sampel awal dimiliki oleh user 2 sebesar 0.019108, sedangkan user 5 memiliki nilai lebih rendah yaitu 0.003185. Hal ini menunjukkan bahwa sebagian besar user hanya terhubung dengan sedikit pengguna lain dalam graph recommendation system.

3.9.2 Top 10 User Degree Centrality Tertinggi

Setelah nilai degree centrality diperoleh, dilakukan pengurutan untuk mencari 10 pengguna dengan nilai degree centrality tertinggi.

Tabel 10. Top 10 User Degree Centrality

user_id	community_id	degree_centrality
276	0	0.0679421
293	0	0.060510
544	3	0.056263
926	20	0.050955
526	3	0.049894
510	14	0.047771
626	3	0.047771
933	0	0.046709
457	0	0.046709
105	3	0.046548

Berdasarkan hasil top 10 degree centrality, user 276 memiliki nilai degree centrality tertinggi sebesar 0.067941, diikuti user 293 sebesar 0.060510 dan user 544 sebesar 0.056263. Hasil ini menunjukkan bahwa user tersebut memiliki koneksi similarity paling banyak dengan pengguna lain sehingga menjadi pusat hubungan dalam graph recommendation system. Selain itu, user dengan degree centrality tinggi berasal dari beberapa komunitas berbeda seperti komunitas 0, 3, 14, 18, dan 20. Hal ini menunjukkan bahwa konektivitas tinggi tidak hanya terpusat pada satu komunitas saja.

3.9.3 Betweenness Centrality

Betweenness centrality digunakan untuk mengukur seberapa sering suatu user menjadi penghubung pada jalur terpendek antar user lain di dalam graph. Semakin tinggi nilainya, maka semakin penting peran user tersebut sebagai penghubung antar komunitas.

user_id	Betweenness
1	0.000250
2	0.003637
3	0.000115
4	0.001207
5	0.000065

Tabel 11. Hasil Betweenness Centrality

Hasil betweenness centrality menunjukkan bahwa sebagian besar pengguna memiliki nilai yang sangat kecil mendekati nol. Hal ini menandakan bahwa mayoritas user tidak berperan besar sebagai penghubung antar bagian graph. Namun terdapat beberapa user dengan nilai lebih tinggi yang menunjukkan adanya node penting dalam menjaga keterhubungan jaringan recommendation system.

3.9.4 Top 10 User Betweenness Centrality Tertinggi

Analisis ini digunakan untuk mengetahui user yang paling berpengaruh sebagai penghubung antar komunitas dalam graph.


Tabel 12. Top 10 User Betweenness Centrality

user_id	community_id	betweenness centrality
293	0	0.034331
275	0	0.025774
457	0	0.024698
592	4	0.023916
26	3	0.023382
933	0	0.023106
549	18	0.021873
177	4	0.020520
526	3	0.019955
537	3	0.019545

Berdasarkan hasil top betweenness centrality, user 293 memiliki nilai tertinggi sebesar 0.034331, diikuti user 276 sebesar 0.025774 dan user 457 sebesar 0.024698. Hal ini menunjukkan bahwa user tersebut memiliki peran penting sebagai penghubung antar kelompok pengguna dalam graph. Selain memiliki banyak koneksi, user-user tersebut juga berfungsi sebagai jalur penghubung utama antar komunitas sehingga memiliki pengaruh besar terhadap struktur network recommendation system.

3.9.5 Visualisasi Degree Centrality

Visualisasi degree centrality menggunakan barchart untuk menunjukkan distribusi nilai centrality pada 10 user dengan koneksi tertinggi.




Gambar 17. Top 10 User dengan Degree Centrality Tertinggi

Visualisasi degree centrality memperlihatkan bahwa terdapat perbedaan nilai centrality yang cukup jelas antar pengguna. User 276 dan user 293 terlihat memiliki nilai paling tinggi dibandingkan user lainnya. Selain itu, warna batang menunjukkan bahwa user dengan koneksi tertinggi berasal dari komunitas yang berbeda-beda, terutama komunitas 0 dan komunitas 3 yang cukup dominan pada posisi top centrality.

3.9.6 Visualisasi Betweenness Centrality

Visualisasi betweenness centrality menggunakan barchart untuk memperlihatkan distribusi pengguna dengan peran penghubung tertinggi dalam graph.




Gambar 18. Top 10 User dengan Degree Centrality Tertinggi

Grafik betweenness centrality menunjukkan bahwa hanya beberapa pengguna yang memiliki nilai cukup tinggi, sedangkan sebagian besar lainnya relatif rendah. User 293 terlihat sebagai pengguna dengan peran penghubung paling dominan dalam graph,

diikuti oleh user 276 dan 457. Hal ini menunjukkan bahwa hanya sedikit node yang berfungsi sebagai bridge antar bagian jaringan recommendation system.

3.9.7 Scatter Plot Degree vs Betweenness

Scatter plot digunakan untuk melihat hubungan antara degree centrality dan betweenness centrality pada setiap user.



Gambar 19. Scatter Plot Degree vs Betweenness

Scatter plot menunjukkan adanya hubungan positif antara degree centrality dan betweenness centrality. Titik-titik data cenderung meningkat seiring bertambahnya nilai degree centrality. Namun terlihat bahwa sebagian besar user terkonsentrasi di area kiri bawah grafik, yang menunjukkan bahwa mayoritas pengguna memiliki koneksi dan pengaruh yang rendah dalam graph. Selain itu, terdapat beberapa titik yang berada jauh dari kumpulan utama data, yang menunjukkan adanya user dengan pengaruh jauh lebih besar dibandingkan pengguna lainnya.

3.9.8 Statistik Centrality

Statistik centrality digunakan untuk melihat distribusi nilai degree centrality dan betweenness centrality secara keseluruhan.

Tabel 13. Statistik Degree Centrality

user_id	Betweenness
Count	943
Mean	0.008076
std	0.009701
min	0

25%	0.001062
50%	0.004246
75%	0.011146
max	0.067941

Tabel 14. Statistik Degree Centrality

user_id	Betweenness
Count	943
Mean	0.002039
std	0.003729
min	0
25%	0
50%	0.000483
75%	0.002421
max	0.034331

Hasil statistik menunjukkan bahwa rata-rata degree centrality sebesar 0.008076 dengan nilai maksimum sebesar 0.067941. Sementara itu, rata-rata betweenness centrality sebesar 0.002039 dengan nilai maksimum sebesar 0.034331. Median degree centrality sebesar 0.004246 dan median betweenness centrality sebesar 0.000483 menunjukkan bahwa sebagian besar pengguna memiliki nilai centrality yang rendah. Perbedaan yang cukup besar antara nilai rata-rata dan maksimum menunjukkan adanya beberapa user yang jauh lebih dominan dibandingkan pengguna lain dalam network recommendation system.

3.9.9 Korelasi Degree dan Betweenness

Analisis korelasi dilakukan untuk mengetahui hubungan antara degree centrality dan betweenness centrality.

Tabel 15. Korelasi Centrality

	degree_centrality	betweenness_centrality
degree_centrality	1	0.741749
betweenness_centrality	0.741749	1

Hasil korelasi menunjukkan nilai hubungan sebesar 0.741749 antara degree centrality dan betweenness centrality. Nilai ini menunjukkan korelasi positif yang cukup kuat. Artinya, pengguna yang memiliki banyak koneksi cenderung juga memiliki peran penting sebagai penghubung antar pengguna dalam graph recommendation system.

3.9.10 Top User Influencer

Analisis top user influencer dilakukan menggunakan influence score yang diperoleh dari penjumlahan degree centrality dan betweenness centrality.


Tabel 16. Statistik Top User Influencer

user_id	community_id	degree_centrality	betweenness_centrality	influence_score
293	0	0.060510	0.034331	0.094841
276	0	0.067941	0.025774	0.093715
457	0	0.046709	0.024698	0.071407
526	3	0.049894	0.019955	0.069849
933	0	0.046709	0.023106	0.069816
544	3	0.056263	0.010290	0.066553
26	3	0.040340	0.023382	0.063722
926	20	0.050955	0.012127	0.063082
896	0	0.039278	0.019101	0.058379
549	18	0.036093	0.021873	0.057966

Berdasarkan hasil influence score, user 293 memiliki nilai tertinggi sebesar 0.094841, diikuti user 276 sebesar 0.093715 dan user 457 sebesar 0.071407. Hasil ini menunjukkan bahwa user tersebut memiliki kombinasi koneksi yang luas sekaligus peran penting sebagai penghubung dalam graph. Komunitas 0 terlihat cukup dominan pada daftar top influencer karena beberapa user dengan influence score tertinggi berasal dari komunitas tersebut.

3.9.11 Visualisasi User Influencer

Visualisasi user influencer digunakan untuk menunjukkan distribusi influence score pada user paling berpengaruh.



Gambar 20. Top User Paling Berpengaruh

Visualisasi influence score menunjukkan bahwa user 293 dan user 276 memiliki pengaruh paling dominan dalam network recommendation system. Selain itu, terlihat adanya selisih influence score yang cukup jelas antara beberapa user teratas dengan pengguna lainnya. Hal ini menunjukkan bahwa struktur graph recommendation system cenderung terpusat pada beberapa node utama yang memiliki koneksi luas sekaligus peran penting sebagai penghubung antar komunitas.

3.10 Recommendation System

Pada tahap ini dibangun sistem rekomendasi film berbasis graph dengan memanfaatkan hubungan similarity antar pengguna yang telah terbentuk pada graph. Setiap pengguna direpresentasikan sebagai *node*, sedangkan hubungan antar pengguna direpresentasikan sebagai *edge* yang menunjukkan tingkat kemiripan preferensi berdasarkan nilai similarity. Rekomendasi diberikan berdasarkan film yang disukai oleh pengguna lain yang memiliki kemiripan preferensi dengan pengguna target (*neighbor*). Untuk menghasilkan rekomendasi yang lebih relevan, digunakan metode Weighted Recommendation Score sehingga kontribusi setiap *neighbor* terhadap skor rekomendasi disesuaikan dengan tingkat similarity yang dimiliki.

3.10.1 Train-Test Split

Sebelum proses rekomendasi dan evaluasi dilakukan, dataset dibagi menjadi data training dan data testing menggunakan metode train-test split dengan proporsi 80:20. Pembagian dilakukan untuk setiap pengguna yang memiliki minimal 10 interaksi agar setiap pengguna tetap memiliki data pada data training maupun data testing. Data training digunakan untuk membangun *graph similarity* dan menghasilkan rekomendasi, sedangkan data testing digunakan untuk mengevaluasi kualitas rekomendasi yang dihasilkan.

Tabel 17. Hasil Train-Test Split

Dataset	Jumlah data
Training	75.598

Testing	19.370
Total	94.968

Berdasarkan Tabel 17 sebanyak 75.598 data digunakan sebagai data training dan 19.370 data digunakan sebagai data testing. Proporsi pembagian data yang digunakan telah memenuhi rasio 80:20 sehingga sebagian besar data dapat dimanfaatkan untuk membangun model rekomendasi, sementara lainnya digunakan untuk menguji kemampuan sistem dalam merekomendasikan film yang relevan kepada pengguna. Pembagian data dilakukan secara acak dengan nilai `random_state=42` untuk memastikan hasil yang diperoleh dapat direproduksi. Dengan adanya pemisahan data training dan data testing, evaluasi sistem dapat dilakukan secara lebih objektif karena data testing tidak digunakan selama proses pembentukan rekomendasi.

3.10.2 Metode Weighted Recommendation Score

Sistem rekomendasi menggunakan metode Weighted Recommendation Score untuk menghitung tingkat relevansi suatu film terhadap pengguna target. Perhitungan skor rekomendasi dilakukan menggunakan persamaan berikut:

$$Score(i) = \frac{\sum(sim(u,v) \times rating(v,i))}{\sum sim(u,v)}$$

Keterangan:

$Score(i)$ = skor rekomendasi film ke- i

$sim(u, v)$ = nilai similarity antar pengguna target dan neighbor

$rating(v, i)$ = rating film ke- i yang diberikan oleh neighbor


Metode ini bekerja dengan memberikan bobot yang lebih besar kepada *neighbor* yang memiliki tingkat kemiripan lebih tinggi terhadap pengguna target. Semakin tinggi nilai *similarity* suatu neighbor, semakin besar pengaruh rating yang diberikan terhadap skor akhir rekomendasi. Berdasarkan implementasi yang dilakukan, sistem terlebih dahulu mengambil sejumlah *neighbor* dengan *similarity* tertinggi dari graph. Film yang telah ditonton oleh pengguna kemudian dihapus dari kandidat rekomendasi sehingga sistem hanya merekomendasikan film yang belum pernah ditonton sebelumnya. Selanjutnya skor rekomendasi dihitung menggunakan weighted average similarity dan diurutkan berdasarkan nilai skor tertinggi. Pendekatan ini memungkinkan sistem menghasilkan sistem menghasilkan rekomendasi yang lebih personal karena mempertimbangkan preferensi pengguna lain yang memiliki karakteristik serupa dengan pengguna target.

3.10.3 Hasil Rekomendasi Top-10

Sebagai contoh implementasi recommendation system, dilakukan pengujian terhadap User 10 untuk menghasilkan sepuluh rekomendasi terbaik.

Tabel 18. Top-10 Rekomendasi untuk User 10

No	Judul Film	Genre	Score	Neighbor Support
1	Christmas Carol, A	Drama	5.0	2
2	Boot, Das	Action	5.0	2
3	Patton	Drama	5.0	2
4	Great Escape, The	Adventure	5.0	1
5	Candidate, The	Drama	5.0	1
6	Alien	Action	5.0	1
7	Big Sleep, The	Film-Noir	5.0	1
8	12 Angry Men	Drama	5.0	1
9	Mr. Smith Goes to Washington	Drama	5.0	1
10	Amadeus	Drama	5.0	1



Gambar 21.Top-10 Rekomendasi untuk User 10

Berdasarkan Tabel 17 dan Gambar 21, seluruh film yang direkomendasikan memperoleh nilai recommendation score sebesar 5,0. Nilai tersebut menunjukkan bahwa film-film yang direkomendasikan mendapatkan prediksi rating tertinggi berdasarkan informasi yang diperoleh dari pengguna lain yang memiliki kemiripan preferensi dengan pengguna target. Film Christmas Carol, A, Boot, Das, dan Patton memiliki nilai *neighbor support* sebesar 2. Hal ini menunjukkan bahwa terdapat dua pengguna yang memiliki kemiripan preferensi dengan pengguna target dan sama-sama memberikan penilaian tinggi terhadap film tersebut. Dukungan dari lebih dari satu neighbor mengindikasikan bahwa rekomendasi tersebut cenderung lebih kuat dan lebih meyakinkan.

Sementara itu, film-film lainnya memiliki nilai *neighbor support* sebesar 1. Meskipun hanya didukung oleh satu neighbor, film tersebut tetap memperoleh skor maksimum karena berasal dari pengguna yang memiliki tingkat similarity tinggi terhadap pengguna target. Berdasarkan visualisasi yang dihasilkan, genre Drama mendominasi daftar rekomendasi dengan enam film dari total sepuluh film yang direkomendasikan.

Selain genre Drama, terdapat pula genre Action, Adventure, dan Film-Noir. Dominasi genre Drama mengindikasikan bahwa pengguna target memiliki pola preferensi yang cenderung serupa dengan pengguna lain yang menyukai film bergenre Drama. Secara keseluruhan, hasil rekomendasi menunjukkan bahwa sistem berhasil memanfaatkan hubungan similarity antar pengguna untuk menghasilkan rekomendasi film yang relevan dan sesuai dengan preferensi pengguna target.

3.11 Evaluasi

Evaluasi dilakukan untuk mengukur kualitas rekomendasi yang dihasilkan oleh sistem. Pada penelitian ini digunakan metrik Precision@10, Recall@10, dan Coverage untuk menilai performa recommendation system pada berbagai nilai threshold similarity.

3.11.1 Precision@K dan Recall@K

Precision@10 digunakan untuk mengukur proporsi film relevan yang berhasil muncul pada daftar rekomendasi.

$$\text{Precision@10} = \frac{\text{Relevant Recommender Items}}{10}$$

Semakin tinggi nilai Precision@10, semakin banyak film yang direkomendasikan dan benar-benar relevan bagi pengguna.

Recall@10 digunakan untuk mengukur kemampuan sistem dalam menemukan film relevan yang terdapat pada data pengujian.

$$\text{Recall@10} = \frac{\text{Relevant Recommender Items}}{\text{Relevant Items}}$$


Semakin tinggi nilai Recall@10, semakin banyak film relevan yang berhasil ditemukan oleh sistem rekomendasi. Selain kedua metrik tersebut, digunakan pula Coverage untuk mengukur persentase pengguna yang berhasil memperoleh rekomendasi dari sistem.

3.11.2 Hasil Evaluasi Recommendation System

Evaluasi dilakukan pada tiga nilai threshold similarity yaitu 0,15; 0,20; dan 0,25 untuk mengetahui pengaruh struktur graph terhadap kualitas recommendation system.

Tabel 18. Hasil Evaluasi Recommendation System

Threshold	Precision@10	Recall@10	Coverage
0,15	0,0452	0,0550	0,9894
0,20	0,0877	0,1133	0,8441
0,25	0,1248	0,1985	0,5536



Gambar 22. Top-10 Rekomendasi untuk User 10

Berdasarkan Tabel 18 dan Gambar 22 terlihat bahwa peningkatan threshold similarity memberikan dampak yang berbeda terhadap kualitas rekomendasi dan coverage pengguna. Nilai Precision@10 mengalami peningkatan dari 0,0452 pada threshold 0,15 menjadi 0,1248 pada threshold 0,25. Peningkatan ini menunjukkan bahwa rekomendasi yang dihasilkan menjadi semakin relevan karena sistem hanya mempertahankan hubungan antar pengguna dengan tingkat similarity yang lebih tinggi. Pola yang sama terlihat pada Recall@10 yang meningkat dari 0,0550 menjadi 0,1985. Hal ini menunjukkan bahwa kemampuan sistem dalam menemukan film-film relevan juga meningkat seiring meningkatnya threshold similarity.

Sebaliknya, nilai Coverage mengalami penurunan dari 98,94% pada threshold 0,15 menjadi 55,36% pada threshold 0,25. Penurunan ini terjadi karena semakin tinggi threshold yang digunakan, semakin sedikit hubungan antar pengguna yang dipertahankan dalam graph sehingga sebagian pengguna kehilangan neighbor dan tidak memperoleh rekomendasi. Hasil tersebut menunjukkan adanya trade-off antara kualitas rekomendasi dan jumlah pengguna yang dapat dilayani oleh sistem.

3.11.3 Analisis Pengaruh Threshold terhadap Evaluasi

Threshold similarity memiliki pengaruh langsung terhadap struktur graph yang digunakan dalam recommendation system. Pada threshold 0,15 graph yang terbentuk relatif padat sehingga hampir seluruh pengguna memiliki neighbor. Kondisi ini menghasilkan coverage yang sangat tinggi yaitu 98,94%, namun kualitas rekomendasi masih rendah karena hubungan yang terbentuk tidak semuanya berasal dari pengguna dengan preferensi yang benar-benar mirip. Ketika threshold dinaikkan menjadi 0,20, hubungan antar pengguna menjadi lebih selektif. Akibatnya nilai Precision@10 meningkat menjadi 0,0877 dan Recall@10 meningkat menjadi 0,1133. Walaupun coverage menurun menjadi 84,41%, sebagian besar pengguna masih dapat memperoleh rekomendasi.

Pada threshold 0,25 hanya hubungan similarity yang kuat yang dipertahankan dalam graph. Kondisi ini menghasilkan Precision@10 dan Recall@10 tertinggi, yaitu masing-masing sebesar 0,1248 dan 0,1985. Akan tetapi, coverage turun cukup signifikan menjadi 55,36% karena banyak pengguna kehilangan koneksi dengan pengguna lain. Hasil ini menunjukkan bahwa semakin tinggi threshold similarity, semakin baik kualitas rekomendasi yang dihasilkan, tetapi semakin sedikit pengguna yang dapat dilayani oleh sistem rekomendasi.

3.11.4 Penentuan Threshold Terbaik

Penentuan threshold terbaik dilakukan dengan mempertimbangkan keseimbangan antara kualitas rekomendasi dan coverage pengguna. Threshold 0,25 memang menghasilkan nilai Precision@10 dan Recall@10 tertinggi, namun coverage yang diperoleh hanya sebesar 55,36%. Artinya hampir setengah pengguna tidak memperoleh rekomendasi dari sistem. Sebaliknya, threshold 0,15 menghasilkan coverage yang sangat tinggi yaitu 98,94%, tetapi kualitas rekomendasinya masih rendah dengan Precision@10 sebesar 0,0452 dan Recall@10 sebesar 0,0550.

Threshold 0,20 memberikan kompromi terbaik antara kedua kondisi tersebut. Pada threshold ini diperoleh Precision@10 sebesar 0,0877, Recall@10 sebesar 0,1133, dan Coverage sebesar 84,41%. Dengan demikian, sebagian besar pengguna masih dapat memperoleh rekomendasi dengan kualitas yang lebih baik dibandingkan threshold 0,15. Oleh karena itu, threshold 0,20 dipilih sebagai threshold terbaik karena mampu memberikan keseimbangan yang optimal antara kualitas rekomendasi dan cakupan pengguna yang dilayani oleh sistem.

BAB IV Penutup

4.1 Kesimpulan

Penelitian ini berhasil membangun *Graph-Based Movie Recommendation System* dengan analisis kemiripan pengguna menggunakan dataset MovieLens 100K yang terdiri dari 100.000 *rating* dari 943 pengguna terhadap 1.682 film. Kemiripan antar pengguna dihitung menggunakan *cosine similarity* pada *user-item matrix* yang telah dinormalisasi dengan metode *mean-centering* untuk mengurangi bias penilaian antar pengguna. Tahap *preprocessing* berhasil meningkatkan kualitas data dengan mengurangi *sparsity* dari 0,937 menjadi 0,8927 melalui proses *filtering* pengguna dan film dengan minimal 20 interaksi, sehingga data yang digunakan menjadi 94.968 *rating* dari 943 pengguna terhadap 939 film.

Analisis struktur *graph* pada tiga nilai *threshold* (0,15; 0,20; dan 0,25) menunjukkan bahwa peningkatan *threshold* menyebabkan jumlah *edge* menurun secara signifikan, jumlah *isolated nodes* meningkat, dan struktur jaringan menjadi lebih terfragmentasi. *Threshold* 0,20 menghasilkan keseimbangan terbaik dengan 3.587 *edge* dan *Largest Connected Component* yang mencakup 82,29% pengguna. Deteksi komunitas menggunakan algoritma Louvain pada *threshold* tersebut berhasil membentuk 168 komunitas dengan nilai *modularity* sebesar 0,5017. Setiap komunitas memiliki genre film dominan yang berbeda, membuktikan bahwa pengelompokan berbasis kemiripan *rating* berhasil menangkap pola preferensi pengguna secara kolektif.

Analisis *centrality* menunjukkan adanya korelasi positif yang kuat sebesar 0,742 antara *degree centrality* dan *betweenness centrality*, dengan User 293 dan User 276 sebagai pengguna paling berpengaruh dalam jaringan berdasarkan *influence score* masing-masing sebesar 0,0948 dan 0,0937. Sistem rekomendasi yang dibangun menggunakan metode *weighted recommendation score* berhasil menghasilkan rekomendasi film yang relevan dengan memanfaatkan hubungan *similarity* antar pengguna dalam *graph*. Hasil evaluasi menunjukkan adanya *trade-off* antara kualitas rekomendasi dan jangkauan pengguna seiring meningkatnya *threshold*. *Threshold* 0,20 dipilih sebagai konfigurasi optimal karena menghasilkan $\text{Precision@10} = 0,0877$, $\text{Recall@10} = 0,1133$, dan $\text{Coverage} = 84,41\%$, yang merupakan keseimbangan terbaik antara ketepatan rekomendasi dan jumlah pengguna yang dapat dilayani oleh sistem.

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya. Pertama, penelitian dapat menggunakan dataset yang lebih besar dan lebih beragam agar pola hubungan antar pengguna yang terbentuk dalam *graph* dapat merepresentasikan preferensi pengguna secara lebih komprehensif. Selain itu, penambahan informasi seperti genre, tahun rilis, atau metadata film lainnya dapat dimanfaatkan untuk meningkatkan kualitas rekomendasi yang dihasilkan.

Kedua, metode perhitungan kemiripan pengguna dapat dikembangkan dengan membandingkan beberapa pendekatan selain *cosine similarity*, seperti Pearson Correlation atau Jaccard Similarity, sehingga dapat diketahui metode yang memberikan

performa terbaik pada graph recommendation system. Ketiga, penelitian selanjutnya dapat mengembangkan sistem rekomendasi berbasis hybrid recommendation dengan menggabungkan pendekatan collaborative filtering dan content-based filtering. Pendekatan tersebut berpotensi mengatasi permasalahan sparsity serta meningkatkan relevansi rekomendasi yang diberikan kepada pengguna.

Keempat, evaluasi sistem rekomendasi dapat diperluas dengan menggunakan metrik tambahan seperti F1-Score, Mean Average Precision (MAP), atau Normalized Discounted Cumulative Gain (NDCG) untuk memperoleh gambaran performa sistem yang lebih menyeluruh. Terakhir, analisis graph dapat dikembangkan dengan menerapkan metode community detection dan centrality lainnya sehingga karakteristik komunitas maupun pengaruh pengguna dalam jaringan dapat dipahami secara lebih mendalam.

4.3 Kendala Selama Proses Pengerjaan

Selama proses pengerjaan penelitian, terdapat beberapa kendala yang dihadapi. Salah satu kendala utama adalah karakteristik dataset yang sparse, karena tidak semua pengguna memberikan rating pada seluruh film yang tersedia. Kondisi tersebut menyebabkan sebagian besar nilai similarity antar pengguna berada di sekitar nol sehingga hubungan antar pengguna cenderung lemah. Selain itu, pemilihan threshold similarity juga menjadi tantangan dalam penelitian ini. Threshold yang terlalu rendah menghasilkan graph yang terlalu padat dengan jumlah edge sangat banyak, sedangkan threshold yang terlalu tinggi menyebabkan graph menjadi terlalu sparse dan banyak pengguna terisolasi. Oleh karena itu, diperlukan beberapa percobaan threshold untuk mendapatkan struktur graph yang seimbang.

Kendala lain muncul pada proses community detection karena jumlah komunitas yang terbentuk sangat dipengaruhi oleh struktur graph hasil threshold similarity. Semakin tinggi threshold, jumlah komunitas meningkat namun graph menjadi semakin terfragmentasi. Pada proses visualisasi graph juga terdapat kendala karena jumlah node dan edge yang cukup besar membuat visualisasi sulit dibaca. Oleh sebab itu, visualisasi dilakukan menggunakan subgraph dan sampling node agar pola komunitas lebih mudah diamati. Selain itu, proses perhitungan similarity dan graph construction membutuhkan waktu komputasi yang cukup besar karena dilakukan pada seluruh pasangan pengguna dalam dataset.

4.4 Rencana Tindak Lanjut

Sebagai tindak lanjut, penelitian selanjutnya dapat menggunakan dataset yang lebih besar dan lebih beragam agar hasil community detection menjadi lebih representatif. Metode similarity lain seperti Pearson Correlation, Adjusted Cosine Similarity, atau Jaccard Similarity juga dapat dibandingkan dengan cosine similarity untuk melihat pengaruhnya terhadap struktur graph dan kualitas komunitas. Selain itu, penelitian berikutnya dapat mengembangkan graph recommendation system berbasis hybrid recommendation dengan menggabungkan collaborative filtering dan content-based filtering agar hasil rekomendasi menjadi lebih akurat. Proses community detection juga dapat dikembangkan menggunakan metode lain seperti Girvan-Newman atau Label Propagation untuk membandingkan hasil komunitas yang terbentuk. Di sisi lain, hasil



community detection dapat dimanfaatkan untuk membangun sistem rekomendasi berbasis komunitas pengguna sehingga rekomendasi film dapat lebih sesuai dengan preferensi kelompok pengguna tertentu. Penelitian selanjutnya juga dapat menambahkan evaluasi sistem rekomendasi menggunakan metrik seperti precision, recall, dan F1-score untuk mengukur kualitas rekomendasi yang dihasilkan.

Daftar Pustaka

- [1] Gulla, J. A., Fidjestøl, A. D., Su, X., Cabaleiro, J. M., Ingvaldsen, J. E., & Sætre, R. (2023). Recommending on graphs: A comprehensive review from a data perspective. *User Modeling and User-Adapted Interaction*, 33(4), 803–888. <https://doi.org/10.1007/s11257-023-09359-w>
- [2] Harper, F. M., & Konstan, J. A. (2015). *MovieLens 100K dataset*. GroupLens Research. <https://grouplens.org/datasets/movielens/100k/>
- [3] Saputra, K. (2025). Perkembangan proyek rancangan sistem rekomendasi film dengan model deep learning berbasis GNN. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 9(4), 6860–6865. <https://doi.org/10.36040/jati.v9i4.14108>
- [4] Yulianti, E. (2022). SGCF: Inductive movie recommendation system with strongly connected neighborhood sampling. *Jurnal Ilmu Komputer dan Informasi*, 15(1). <https://doi.org/10.21609/jiki.v15i1.1066>
- [5] Zhang, J.-C., Mohd Zain, A., Zhou, K.-Q., Chen, X., & Zhang, R.-M. (2024). A review of recommender systems based on knowledge graph embedding. *Expert Systems with Applications*, 250, Article 123876. <https://doi.org/10.1016/j.eswa.2024.123876>



UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM
PRODI S1 SAINS DATA

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
<https://datascience.fmipa.unesa.ac.id>